

Etapa 1 - TP Final - INF420

Alunos:

Carlos Eduardo Pereira Oliveira - 116233

Luis Felipe Martins Pereira - 112710

O projeto tem como tema a classificação automática da dificuldade de questões de programação, utilizando técnicas de aprendizado de máquina e modelos de linguagem (LLMs). Como extensão, será explorada a recomendação de exercícios, baseada na similaridade entre enunciados e no nível de dificuldade previsto.

O objetivo é desenvolver um sistema capaz de prever automaticamente o nível de dificuldade (fácil, médio ou difícil) de questões de programação a partir de seus enunciados textuais.

Será utilizada uma base de dados fornecida por um professor do Departamento de Informática, contendo questões previamente classificadas (pelos alunos) quanto à dificuldade. A partir dessa base, o sistema será treinado para generalizar o conhecimento adquirido e classificar novas questões não rotuladas.

Para a tarefa de classificação, serão utilizadas técnicas de aprendizado de máquina supervisionado de diferentes famílias, incluindo, mas não limitado a: Regressão Logística, K-Nearest Neighbors (KNN), Support Vector Machines (SVM) e Random Forest.

Os enunciados das questões serão transformados em representações numéricas utilizando técnicas de Processamento de Linguagem Natural (PLN), como TF-IDF e, possivelmente, embeddings semânticos. Para a avaliação dos modelos, serão usadas métricas de acurácia e F1-score.

Modelos de linguagem (LLMs) serão utilizados em diferentes etapas do projeto:

1. Baseline de classificação: o LLM será utilizado para classificar diretamente a dificuldade das questões, permitindo comparação com os modelos tradicionais;
2. Geração de explicações: o modelo será utilizado para justificar a classificação atribuída, oferecendo interpretabilidade aos resultados;
3. Extração de características: o LLM poderá identificar automaticamente conceitos presentes nos enunciados (ex.: recursão, estruturas de dados), auxiliando na análise da dificuldade;